

Πρόβλεψη Εξέλιξης Cascades (Growth Prediction)

Υλοποίηση & πειράματα βασισμένα στο “Can Cascades be Predicted?” (Cheng et al., WWW 2014)

1. Στόχος

Διατυπώνουμε το πρόβλημα cascade growth prediction όπως στο [1]. Για cascades που φτάνουν μέγεθος k , ορίζουμε το $f(k)$ ως τη διάμεσο του τελικού μεγέθους τους και προβλέπουμε δυαδικά αν ένα cascade θα ξεπεράσει το $f(k)$.

2. Δεδομένα

Κάθε γραμμή περιέχει (message_id, root_user_id, publish_time, retweet_number_24h, retweets). Τα retweets είναι items «u1/u2/.../un:t» (μονοπάτι διάδοσης + χρόνος σε s από την αρχική δημοσίευση). Παράγονται datasets για $k=1..200$, κρατώντας cascades με τελικό μέγεθος $\geq k$.

3. Προεπεξεργασία & Labels

Δύο περάσματα: (i) υπολογισμός $f(k)$ από τα τελικά μεγέθη (άνω διάμεσος) και (ii) εξαγωγή χαρακτηριστικών από τα πρώτα k γεγονότα και label $y=1$ αν $\text{total} \geq f(k)$, αλλιώς 0. Τα datasets αποθηκεύτηκαν ως parquet (features_ k .parquet).

4. Χαρακτηριστικά

Χρησιμοποιήθηκαν 15 features σε 3 ομάδες:


- Temporal (7): time_ k , inter-arrival stats (mean 1o/2o μισό, mean/std), trend, burstiness (CV).
- Structural (6): depth (max/avg/p90), root/max out-degree, #leaves.
- User proxy (2): unique/duplicate leaf users στα πρώτα k γεγονότα.

5. Μοντέλα & Εκπαίδευση

Μοντέλα: Logistic Regression και MLP (1 hidden layer, ReLU, dropout). Standardization στο training set. Split 70/15/15 train/val/test με stratification. Adam (lr=1e-3, wd=1e-4), batch=256, early stopping στο validation AUC (patience=10, max 100 epochs).

6. Αποτελέσματα

Η απόδοση αυξάνει έντονα για μικρά k (1-10) και στη συνέχεια σταθεροποιείται. Καλύτερο MLP στο $k=119$: Accuracy 83.5%, ROC-AUC 91.2%. Το MLP υπερτερεί σχεδόν σε όλα τα k .




Σχήμα 1: Accuracy και ROC-AUC ως συνάρτηση του k (LogReg vs MLP).

Πίνακας 1: Ενδεικτικές μετρικές (test).

k	Cascades (N)	LogReg Acc	LogReg AUC	MLP Acc	MLP AUC
1	119.313	52.2%	67.5%	63.8%	68.1%
5	119.313	69.4%	80.9%	77.5%	84.6%
10	112.902	77.5%	88.2%	82.1%	90.0%
25	68.024	76.4%	86.3%	80.6%	88.7%
50	44.711	76.3%	86.0%	81.0%	88.7%
100	26.446	77.7%	88.2%	82.4%	89.8%
119	22.500	78.2%	89.2%	83.5%	91.2%
200	14.262	—	—	81.1%	89.7%

7. Ablation (Leave-One-Out)

Η αφαίρεση μεμονωμένου feature έχει μικρή επίδραση ($< \sim 0.25$ pp κατά μέσο όρο). Η αφαίρεση όλης της temporal ομάδας οδηγεί σε μεγάλη πτώση: 25.3 pp (Accuracy) και 30.7 pp (AUC) για MLP (και 21.9/30.7 pp για LogReg).



Σχήμα 2: Μέση υποβάθμιση (pp) όταν αφαιρείται κάθε feature (MLP).

8. Συμπεράσματα & Παραδοχές

- Temporal signals είναι οι ισχυρότεροι προγνωστικοί παράγοντες, όπως στο [1].
- Τα structural/user-proxy features προσθέτουν μικρό αλλά μετρήσιμο κέρδος και η απόδοση είναι σχετικά «robust».
- Δεν υλοποιήθηκε shape prediction (π.χ. Wiener index).
- Παραδοχή: το $f(k)$ υπολογίστηκε σε 1ο πέραςμα στο σύνολο των cascades (σε αυστηρό setup: μόνο στο training split).

Βιβλιογραφία

[1] J. Cheng, L. A. Adamic, P. A. Dow, J. Kleinberg, J. Leskovec. Can Cascades be Predicted? Proc. WWW 2014. DOI: 10.1145/2566486.2567997.